Notebook DM1

November 17, 2022

```
[3]: # import the necessary libraries
     import pandas as pd
     import numpy as np
     from random import *
     from math import *
[4]: # import the data
     df=pd.read_table('acc_usines.txt', header=None, names=["num_acc"])
     df.head()
[4]:
        num_acc
              4
     0
              5
     1
     2
              4
     3
              1
```

[5]: y=np.array(df.num_acc) # convert the data into array
T=len(y) # length of data

y contains our data. In the next cells, we will be using the following notations in code:

l denotes λ , le point de changement

0

d: denotes δ , the poisson parameter if t>l

g: denotes γ , the poisson parameter if t<=l

1 Utility Functions

$$S_k = \sum_{t=1}^k y_t$$

```
[41]: # for l=k, calculate the sum of y_t from 1 til k
    #this sum appears in the conditional distribution of l
    #please refer to the excercice solution
    def s(k:int):
        s=0
        for i in range(k+1):
        s+=y[i]
        return s # returns a sum
```

```
\bar{S}_k = \sum_{k=1}^T y_t
[42]: # for l=k, calculate the sum of y_t from k+1 til T
       #this sum appears in the conditional distribution of l
       # please refer to the exercice solution
       def s_barre(k:int):
           s barre=0
           for i in range(k+1,(len(y))):
                s_barre+=y[i]
           return s_barre
                                          # returns a sum
      \mathbb{P}\left(\lambda = k \mid \gamma, \delta, y\right) = \frac{\exp(-k(\gamma - \delta)\gamma^{S_k}\delta^{\bar{S_k}}}{\sum_{k=1}^{T-1}\exp(-k(\gamma - \delta)\gamma^{S_k}\delta^{\bar{S_k}}}
[10]: # la loi de probabilité marginale de lambda(l) sachant gamma(g), delta(d) et y
       # c'est la posteriori de l sachant les autres paramètres
       def P(1,d,g):
           nom=0
           for j in range(1,len(y)):
                nom+=(np.exp(-j*(g-d)))*(g**(s(j)))*(d**(s_barre(j)))
           p=(np.exp(-1*(g-d)))*(g**(s(1)))*(d**(s_barre(1)))
           proba_cond_lambda=(p/nom)
           return proba_cond_lambda
[12]: lambda=range(1,len(y))
                                            # the range the possible values of lmabda(l)
[13]: # retourne une liste de probalités de chaque valeurs de lambda sachant q,d et y
       # utile pour la simulation de la loi de l
       def list_proba_cond_lambda(d,g):
           list_proba_cond_lambda=[]
           for e in _lambda:
                list_proba_cond_lambda.append(P(e,d,g))
           return list_proba_cond_lambda
[14]: # retourne un entier entre 1 et T-1
       # la focntion simule la loi de l
       def simul(valeurs,probas):
           assert len(valeurs) == len(probas)
           nb=random()
           curseur=0
           for i in range(len(valeurs)):
                if curseur<=nb and nb<curseur+probas[i]:</pre>
                     return valeurs[i]
                else:
                     curseur+=probas[i]
```

2 Algorithme de gibbs pour la simulation des lois posteriori


```
\gamma \mid \delta, \lambda, y \sim G(a_1 + S_\lambda, \lambda + a_2)
      \delta \mid \gamma, \delta, y \sim G(d_1 + \bar{S}_{\lambda}, T - \lambda + d_2)
      \mathbb{P}\left(\lambda = k \mid \gamma, \delta, y\right) = \frac{\exp(-k(\gamma - \delta)\gamma^{S_k} \delta^{\bar{S_k}}}{\sum_{k=1}^{T-1} \exp(-k(\gamma - \delta)\gamma^{S_k} \delta^{\bar{S_k}}}
[15]: def gibbs_sampling(g_0,d_0,l_0,a_1,a_2,d_1,d_2,n_iter):
            sample=np.empty((n_iter,3), dtype=float)
            1=1_0
            for k in range(n_iter):
                 L=[]
                 g_k=np.random.gamma(a_1+s(1), (1/(1+a_2)))
                 d_k=np.random.gamma(d_1+s_barre(1),(1/(T-1+d_2)))
                 l_k=simul(_lambda,list_proba_cond_lambda(d_k,g_k))
                 L.append(g_k)
                 L.append(d_k)
                 L.append(l_k)
                 sample[k]=L
                 1=1_k
            return sample
[16]: # taille de l'échantillon 200
        # initialisation des paramètres
       sample_=gibbs_sampling(0,0,1,0,0,0,0,200)
[44]: # as we know, les MCMC convergent vers la vraie distribution quand n_iter tend_
        →vers l'infini
        # ici, on a pris les 100 derniers échantillons
       sample=sample_[100:]
[29]: # représentation des échantillons sous forme d'un dataframe for easyu
        \rightarrow manipulations
       dd=pd.DataFrame(sample,columns=['g','d','l'])
       dd.head()
[29]:
                                        1
       0 3.479424 0.931949 35.0
       1 3.528910 0.937035 35.0
       2 3.616757 0.858208 41.0
       3 3.201354 0.824543 41.0
       4 2.945311 0.857086 38.0
[30]: # génération des statistiques
       dd.describe()
```

```
[30]:
             100.000000
                          100.000000
                                       100.000000
      count
      mean
                3.209230
                             0.893896
                                        38.780000
      std
                0.307484
                             0.106770
                                         2.389286
                2.462608
                             0.604916
                                        34.000000
      min
      25%
                2.987881
                             0.823685
                                        38.000000
      50%
                3.199654
                             0.894752
                                        39.000000
      75%
                3.412206
                             0.962149
                                        40.000000
                4.211965
                             1.117734
                                        45.000000
      max
```

3 Représentation graphiques des postérioris


3.1 Postériori de λ

[46]: hist=dd.hist(column='l',figsize=(3,2))



3.2 Postériori de γ


[39]: dd.hist(column='g',figsize=(3,2))



3.3 Postériori de δ

[40]: dd.hist(column='d',figsize=(3,2))

[40]:



Calcul du nombre d'accidents avant et aprés ce changement ?

[23]: s(39)

[23]: 125

[24]: s_barre(39)

[24]: 66

[25]: s(41)

[25]: 128

[26]: s_barre(41)

[26]: 63

[27]: s(37)

[27]: 120

[28]: s_barre(37)

[28]: 71

4 Interprétation & Conclusion

D'après les statistiques issues des lois a postériori, le point de changement λ (mean=39, std=2) est situé entre 1888 et 1892. le nombre d'accident avant le point de changement est entre 120 et 128. Ainsi, le nombre d'accident après le point de changement a diminué et situé entre 63 et 71.